딥러닝을 이용한 자연어 처리

01 텍스트 전처리 및 단어 임베딩

목차

01. 자연어 처리

02. 텍스트 전처리

03. 단어 임베딩

04. word2vec

05. fastText

01

자연어 처리

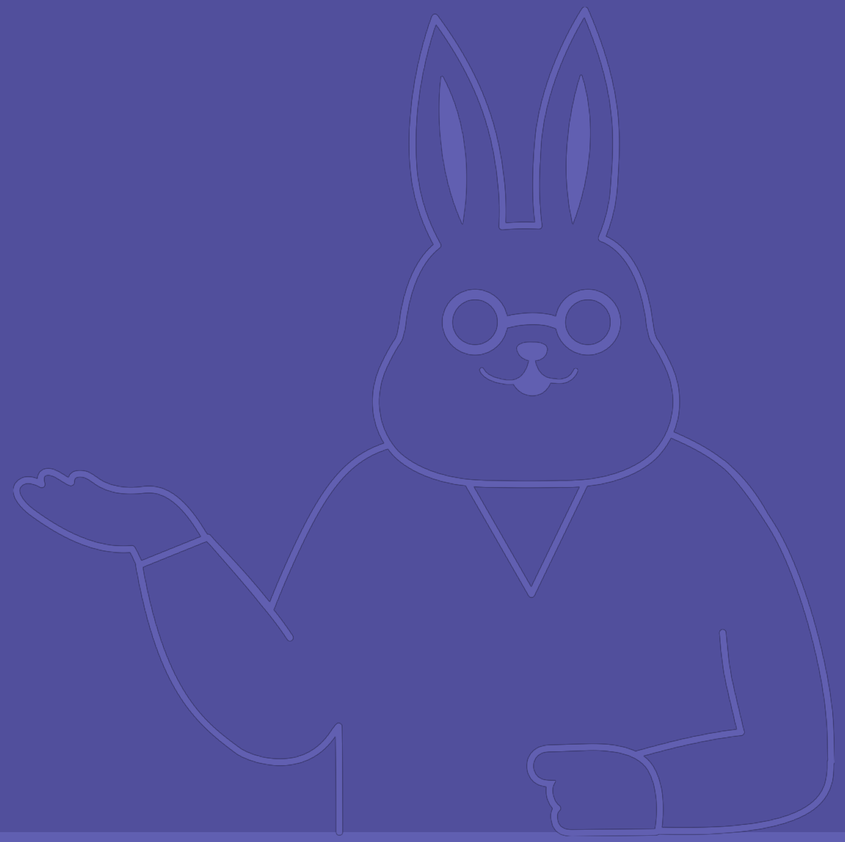

자연어 처리란

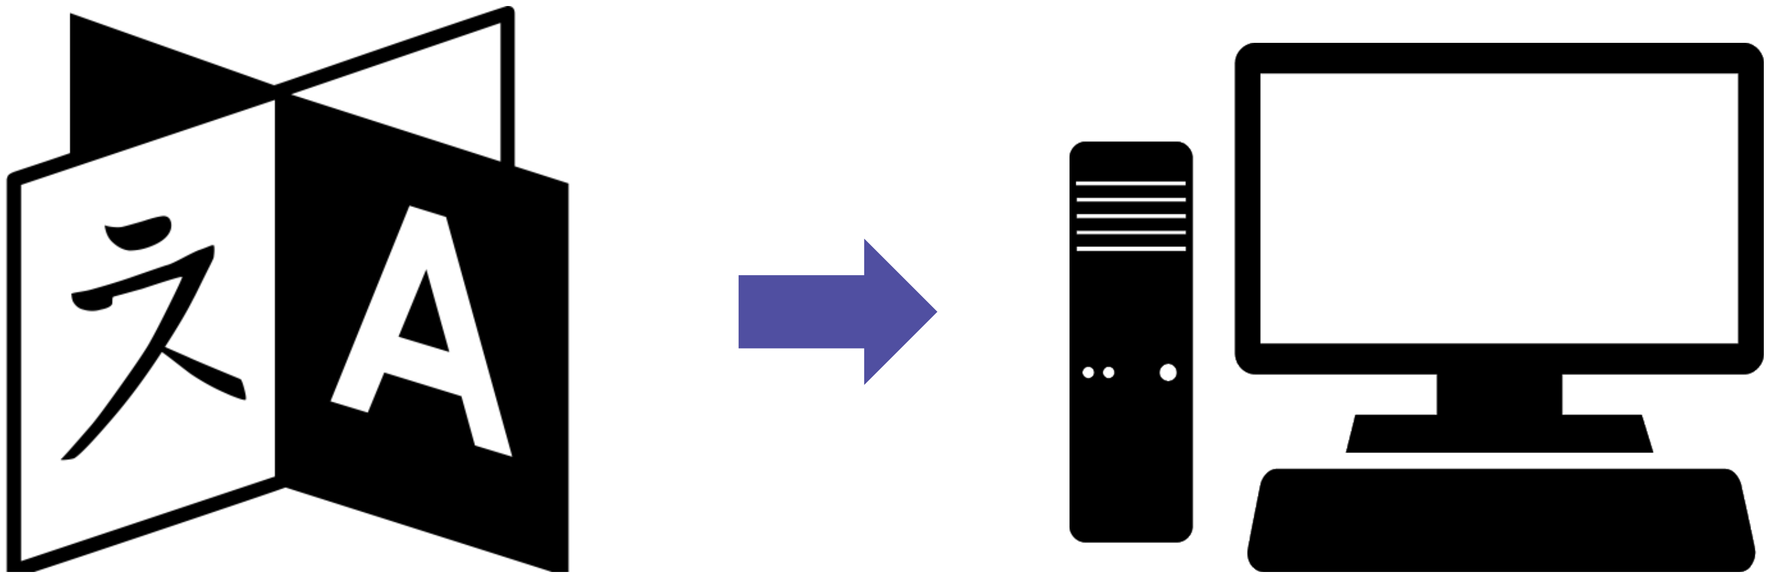

자연어 처리(Natural Language Processing, NLP)는 컴퓨터를 통해 인간의 언어를 분석 및 처리하는 인공지능의 한 분야

자연어 처리의 적용 사례

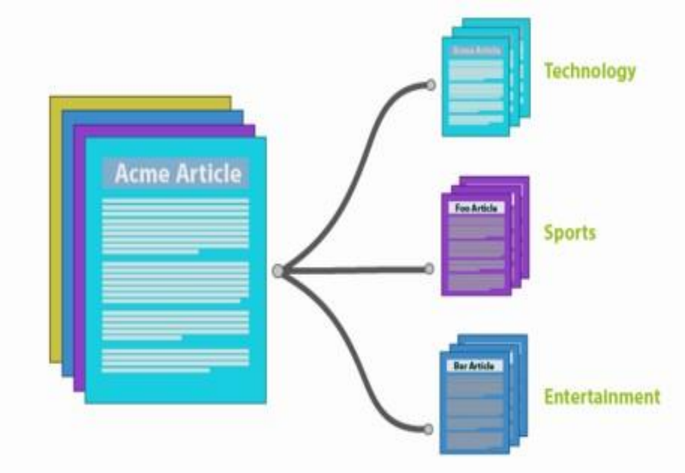

문서 분류

키워드 추출

감정 분석

자연어 처리 + 머신러닝

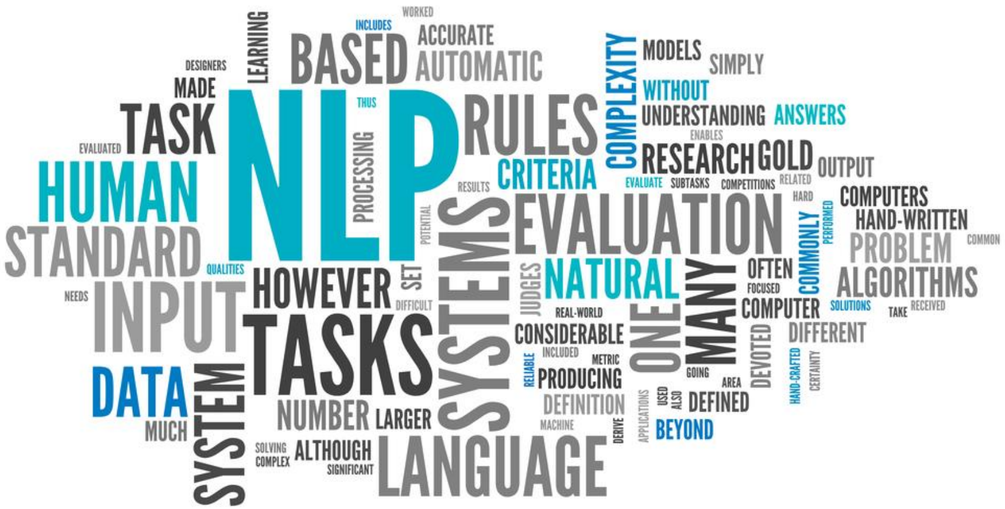

학습 가능한 데이터양의 증가 및 **연산 처리 속도의 발전**으로 자연어 처리 또한
더욱 복잡한 머신러닝 알고리즘 적용 가능

머신러닝 기반 자연어 처리의 적용 사례

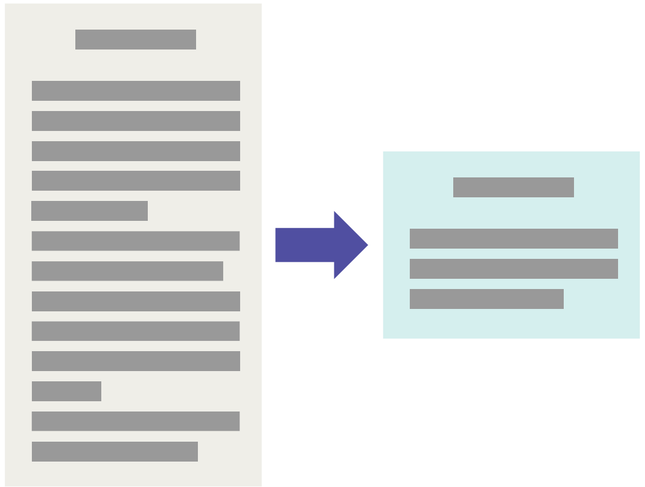

문서 요약

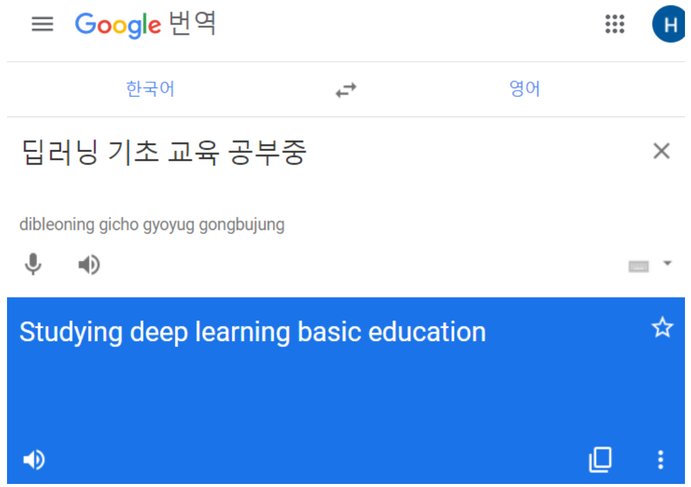

기계 번역

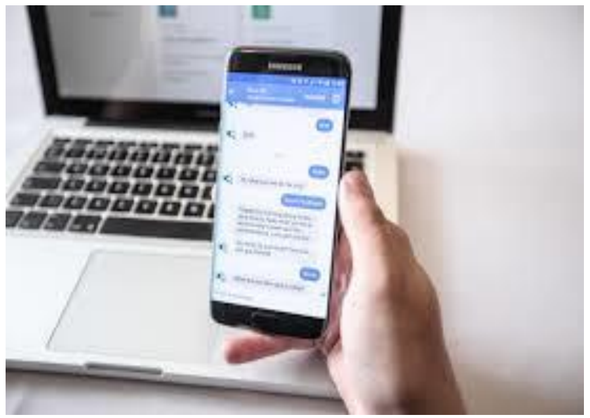

Chat bot

02

텍스트 전처리

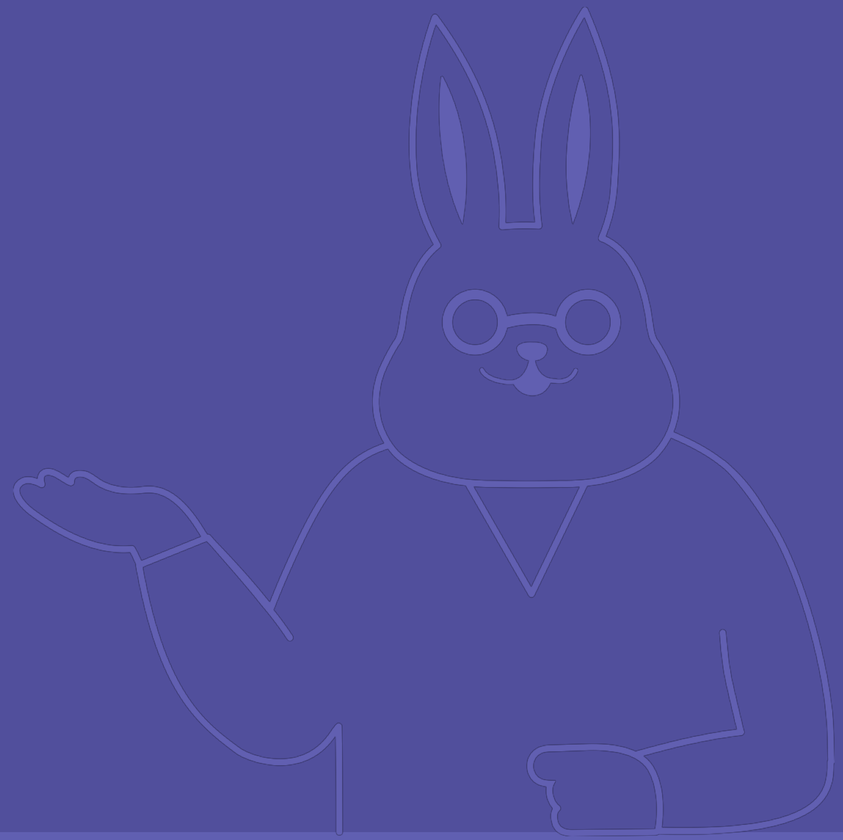

모델링을 위한 데이터 탐색 및 전처리

데이터 탐색

데이터 통계치
변수별 특징
…

데이터 전처리

이상치 제거
정규화 (normalization)
…

모델링을 위한 데이터 탐색 및 전처리

데이터 탐색

단어의 개수
단어별 빈도수
…

데이터 전처리

특수기호 제거
단어 정규화
…

Tokenization

텍스트 1 : Hello, my name is Elice! What is your name?

텍스트 1 : Hello, | my | name | is | … | name?

토큰화(tokenization)는 주어진 텍스트를 각 단어 기준으로 분리하는 것을 의미

Tokenization

텍스트 1 : Hello, my name is Elice! What is your name?

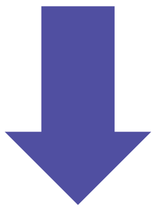

텍스트 1 : Hello, | my | name | is | … | name?

가장 기본적인 토큰화의 기준은 **공백**

Tokenization

텍스트 1 : Hello, my name is Elice! What is your name?

텍스트 1 : hello | my | name | is | … | name

소문자 처리 및 특수기호 제거를 통해 동일한 의미의 토큰은 동일한 형태로 변환

단어의 개수 및 빈도수 확인

Example

```
counter = dict()

with open(파일명, 'r') as f:
    for line in f:
        for word in line.rstrip().split():
            if word not in word_counter:
                word_counter[word] = 1
            else:
                word_counter[word] += 1
```

자연어 처리 + 머신러닝

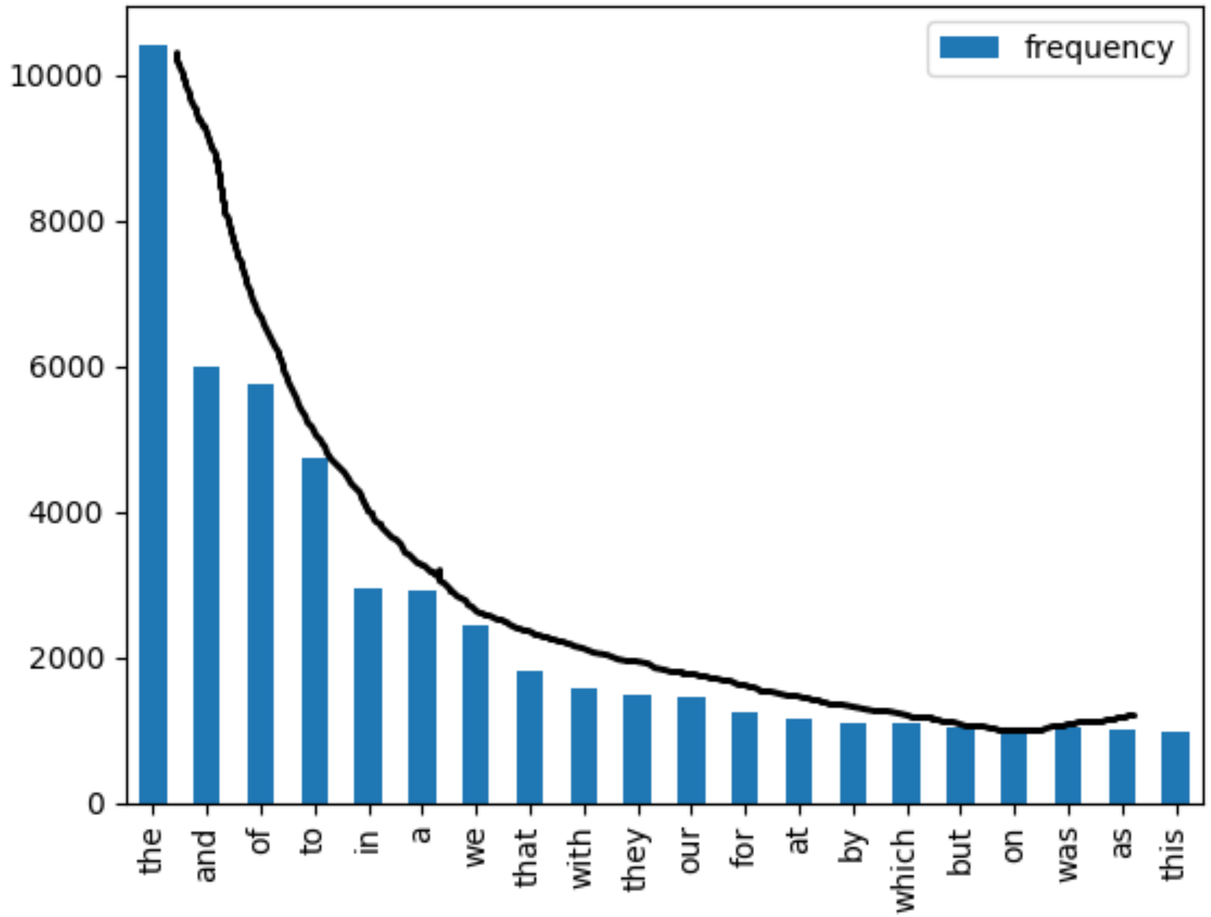

대부분 단어 빈도수의 분포는 **지프의 법칙(Zipf's law)**을 따름

전처리 I: 특수 기호 제거

Example

```
import re

word = "123hello993 $!%eli$@ce^"
regex = re.compile('[^a-z A-Z]')

print(regex.sub('', word))
# hello elice
```

re: 정규표현식 라이브러리

정규표현식: 정의하는 규칙을 가진 문자열 집합

전처리 II: Stopword 제거

['i', 'me', 'my', 'myself', 'we', 'our', 'ours', 'ourselves', 'you', "you're", "you've", "you'll", "you'd", 'your', 'yours', 'yourself', 'yourselves', 'he', 'him', 'his', 'himself', 'she', "she's", 'her', 'hers', 'herself', 'it', "it's", 'its', 'itself', 'they', 'them', 'their', 'theirs', 'themselves', 'what', 'which', 'who', 'whom', 'this', 'that', "that'll", 'these', 'those', 'am', 'is', 'are', 'was', 'were', 'be', 'been', 'being', 'have', 'has', 'had', 'having', 'do', 'does', 'did', 'doing', 'a', 'an', 'the', 'and', 'but', 'if', 'or', 'because', 'as', 'until', 'while', 'of', 'at', 'by', 'for', 'with', 'about', 'against', 'between', 'into', 'through', 'during', 'before', 'after', 'above', 'below', 'to', 'from', 'up', 'down', 'in', 'out', 'on', 'off', 'over', 'under', 'again', 'further', 'then', 'once', 'here', 'there', 'when', 'where', 'why', 'how', 'all', 'any', 'both', 'each', 'few', 'more', 'most', 'other', 'some', 'such', 'no', 'nor', 'not', 'only', 'own', 'same', 'so', 'than', 'too', 'very', 's', 't', 'can', 'will', 'just', 'don', "don't", 'should', "should've", 'now', 'd', 'll', 'm', 'o', 're', 've', 'y', 'ain', 'aren', "aren't", 'couldn', "couldn't", 'didn', "didn't", 'doesn', "doesn't", 'hadn', "hadn't", 'hasn', "hasn't", 'haven', "haven't", 'isn', "isn't", 'ma', 'mightn', "mightn't", 'mustn', "mustn't", 'needn', "needn't", 'shan', "shan't", 'shouldn', "shouldn't", 'wasn', "wasn't", 'weren', "weren't", 'won', "won't", 'wouldn', "wouldn't"]

문법적인 기능을 지닌 단어 및 불필요하게 자주 발생하는 단어를 제거

전처리 II: Stopword 제거

Example

```
import nltk
from nltk.corpus import stopwords

sentence = ["the", "green", "egg", "and", "ham", "a", "an"]
stopwords = stopwords.words('english') # 리스트를 반환
new_sentence = [word for word in sentence if word not in stopwords]

print(new_sentence)
# ["green", "egg", "ham"]
```

전처리 II: Stopword 제거

Example

```
import nltk
from nltk.corpus import stopwords

new_stopwords = ["none", "는", "가"] # 신규 stopword
stopwords = stopwords.words('English') # 리스트를 반환

stopwords += new_stopwords
```

전처리 II: Stemming

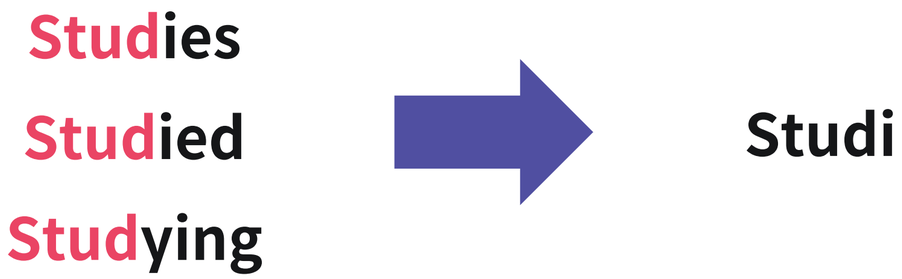

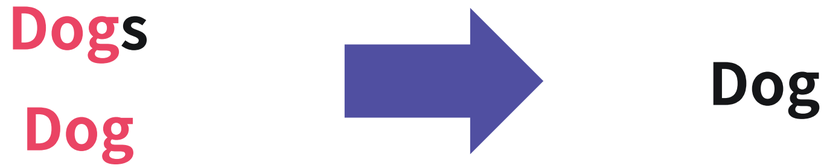

동일한 의미의 단어이지만, 문법적인 이유 등
표현 방식이 다양한 단어를 공통된 형태로 변환

전처리 II: Stemming

Example

```
import nltk
from nltk.stem import PorterStemmer

words = ["studies", "studied", "studying", "dogs", "dog"]

stemmer = PorterStemmer()

for word in words:
    print(stemmer.stem(word)) # studi, studi, studi, dog, dog
```

03

단어 임베딩

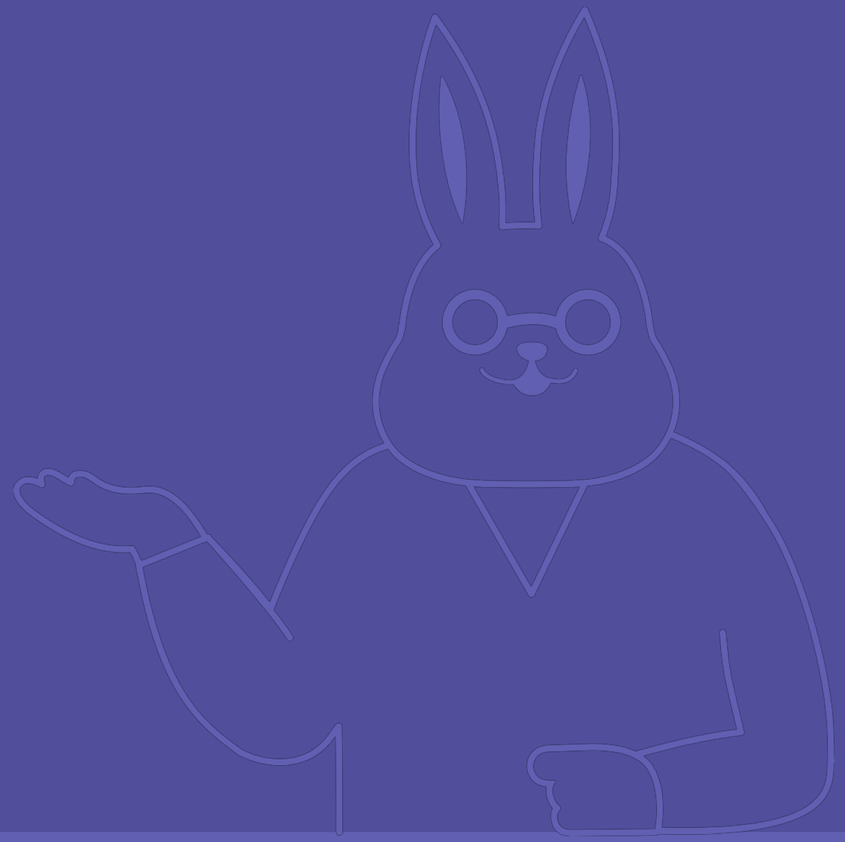

컴퓨터 - 언어

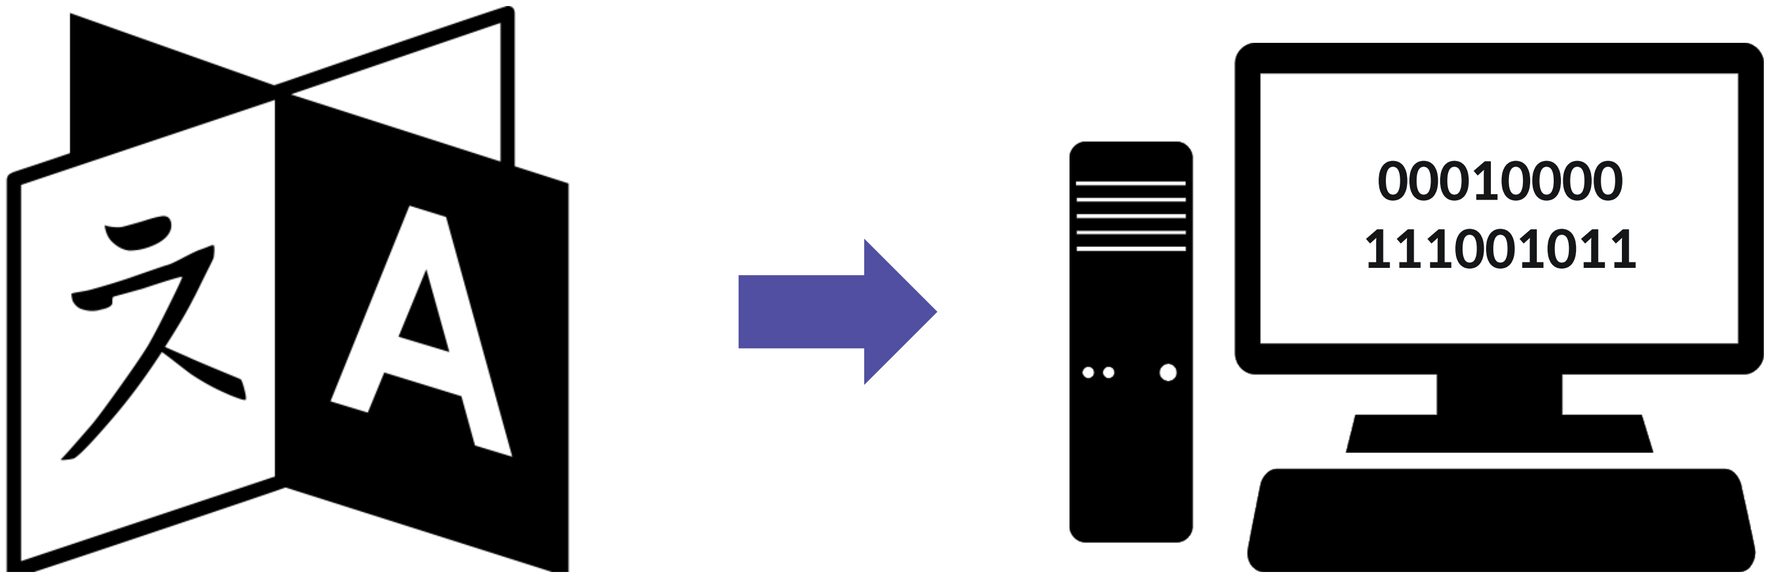

컴퓨터는 텍스트를 포함하여 모든 데이터를 **0과 1**로 처리

컴퓨터 - 언어

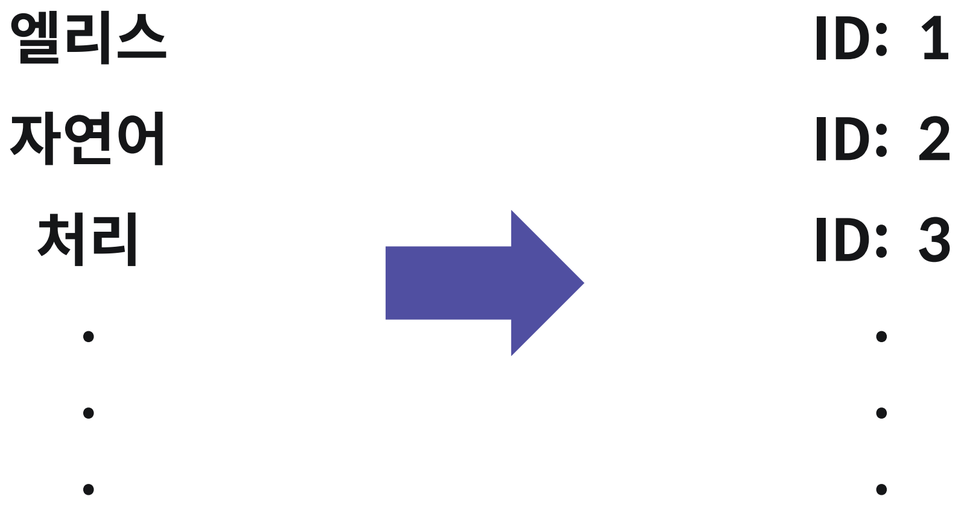

자연어의 기본 단위인 단어를 **수치형 데이터**로 표현하는 것이 중요

단어 임베딩

엘리스 [0.23, 0.401, 0.482, 0.42, 0.99 …]

자연어 [0.03, 0.101, 2.682, 0.62, 0.08 …]

처리  [1.03, 0.222, 0.382, 0.32, 1.28 …]

.
.
.

.
.
.

단어 임베딩이란 각 단어를 **연속형 벡터**로 표현하는 방법을 의미

단어 임베딩

서울에 살고 있는 **엘리스**는 **강아지**를 좋아한다.

뉴욕에 살고 있는 **찰리**는 **고양이**를 좋아한다.

비슷한 문맥에서 발생하는 단어는 **유사한 의미**를 지님

단어 임베딩

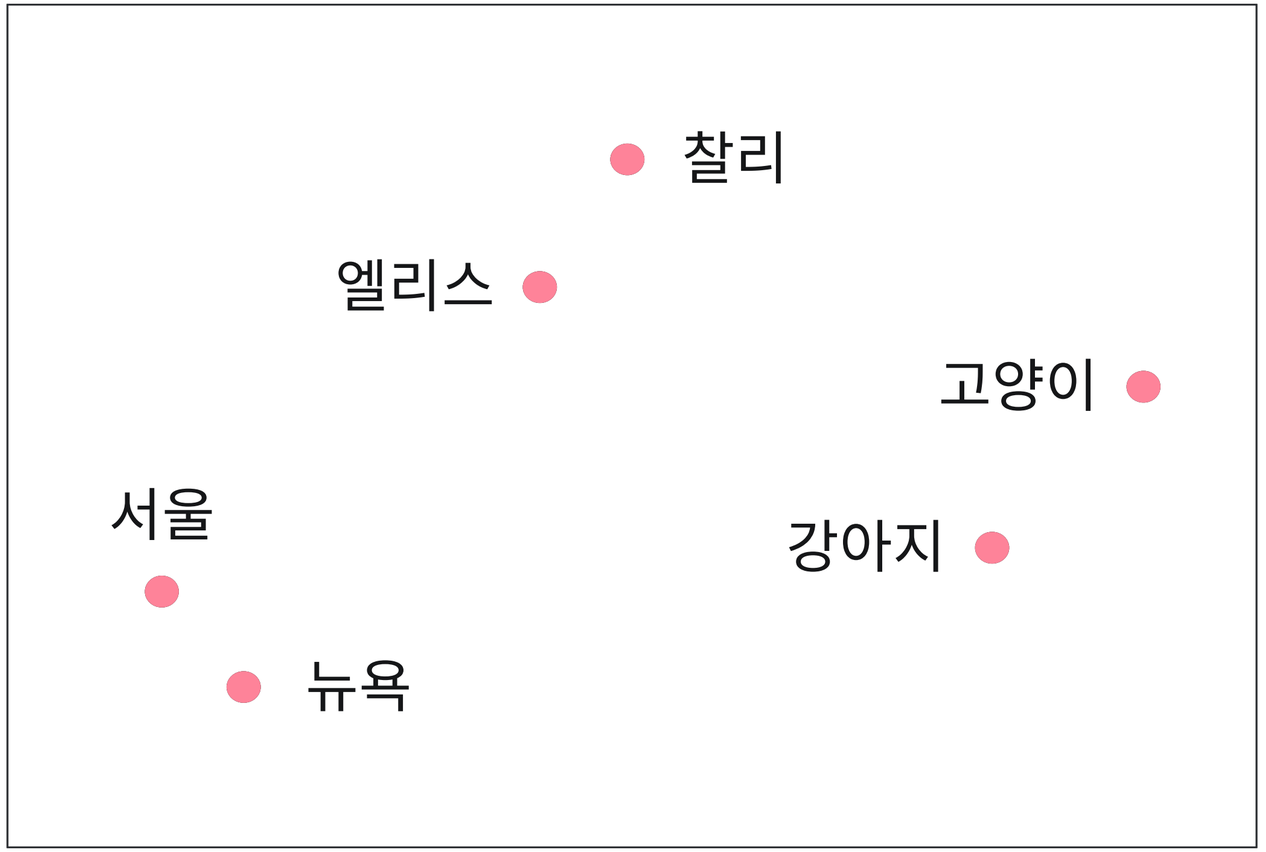

유사한 단어의 임베딩 벡터는 **인접한 공간**에 위치

단어 임베딩

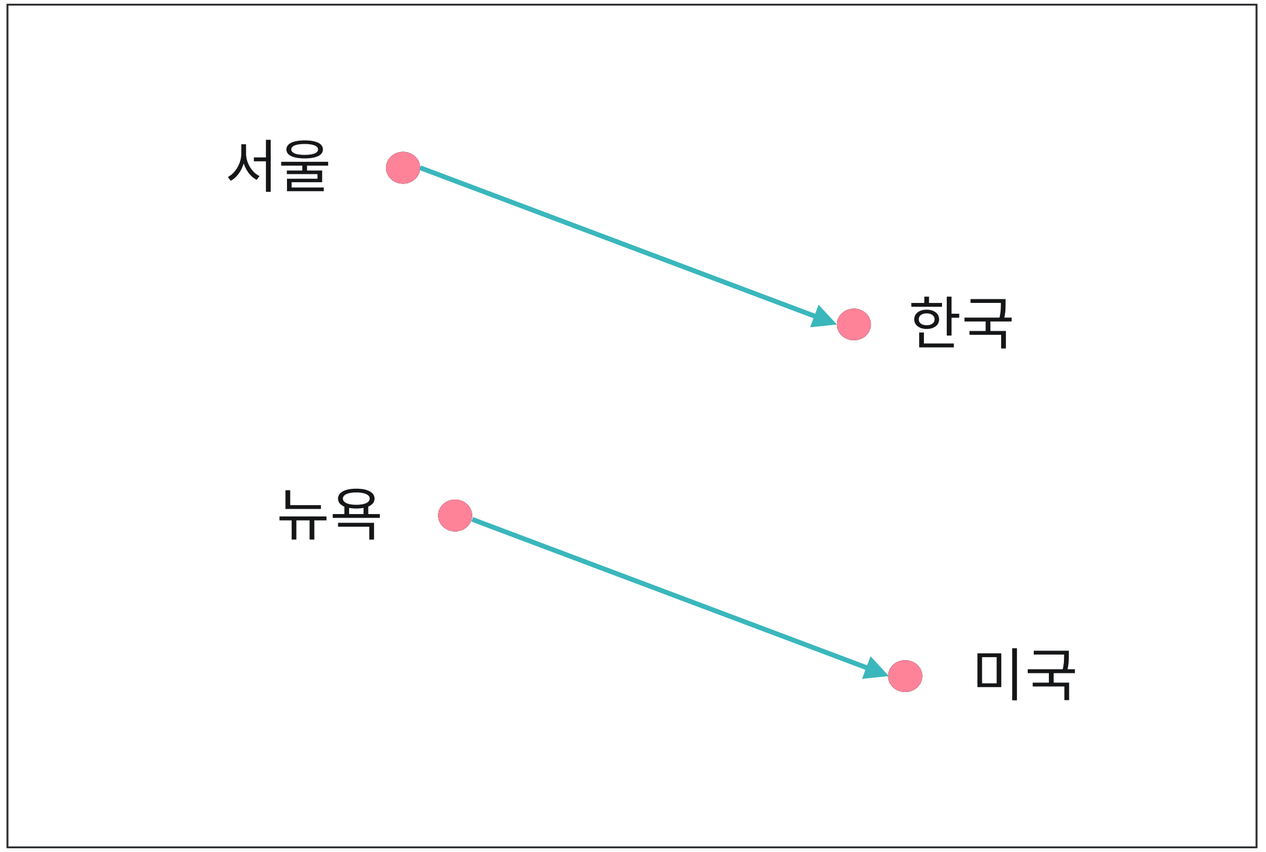

임베딩 벡터 간 합과 차로 단어의 의미적 특징을 활용 가능

04

word2vec

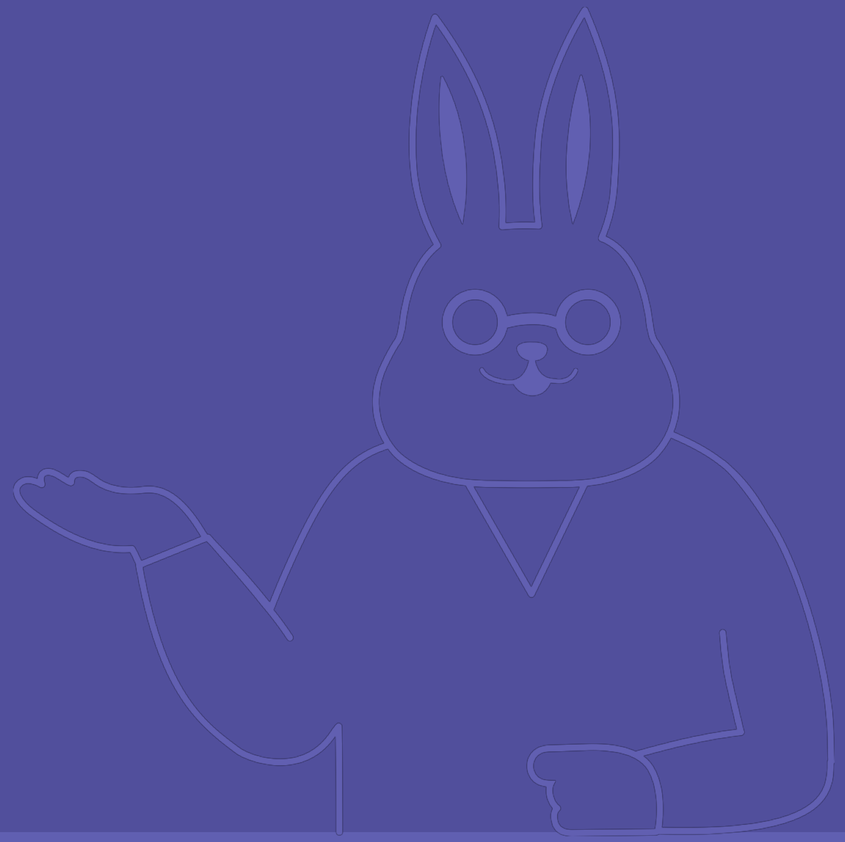

word2vec

서울에 살고 있는 **엘리스는** 강아지를 좋아한다.

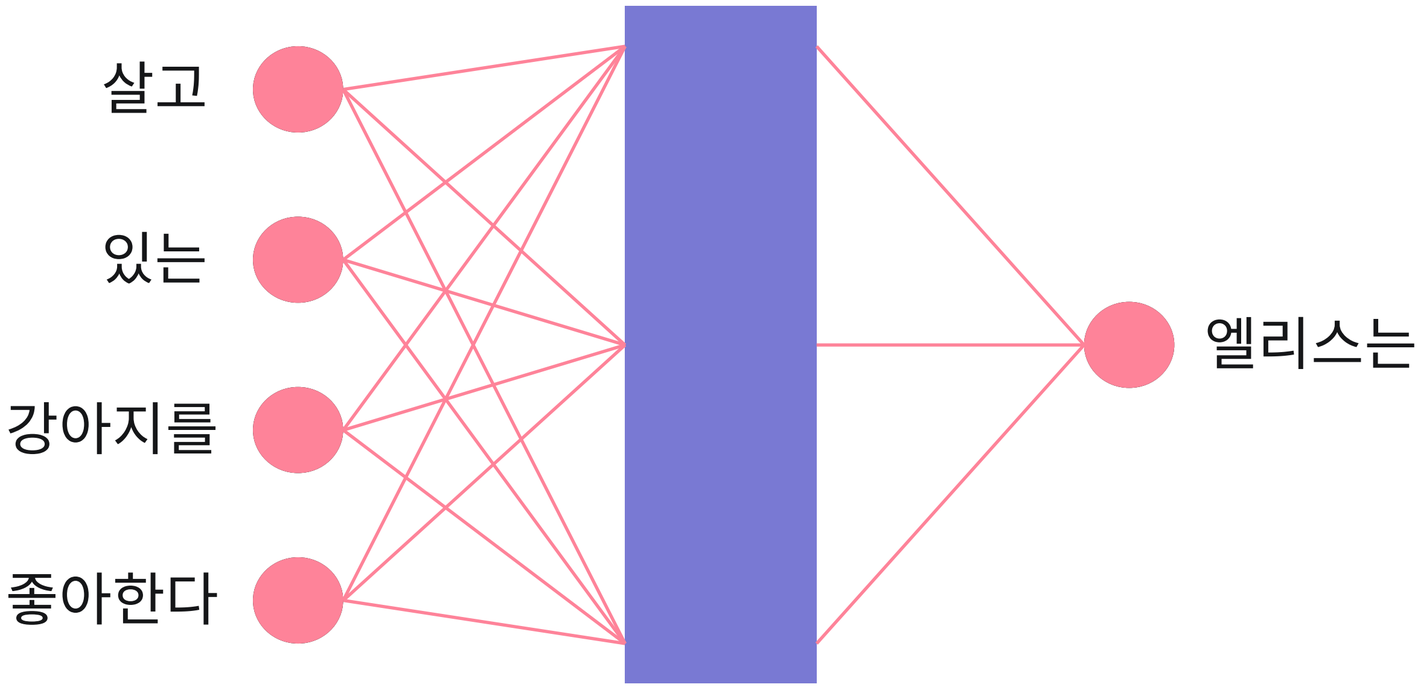

신경망(Neural Network)을 통해 단어 임베딩 벡터를 학습

word2vec

서울에 살고 있는 **엘리스는** 강아지를 좋아한다.

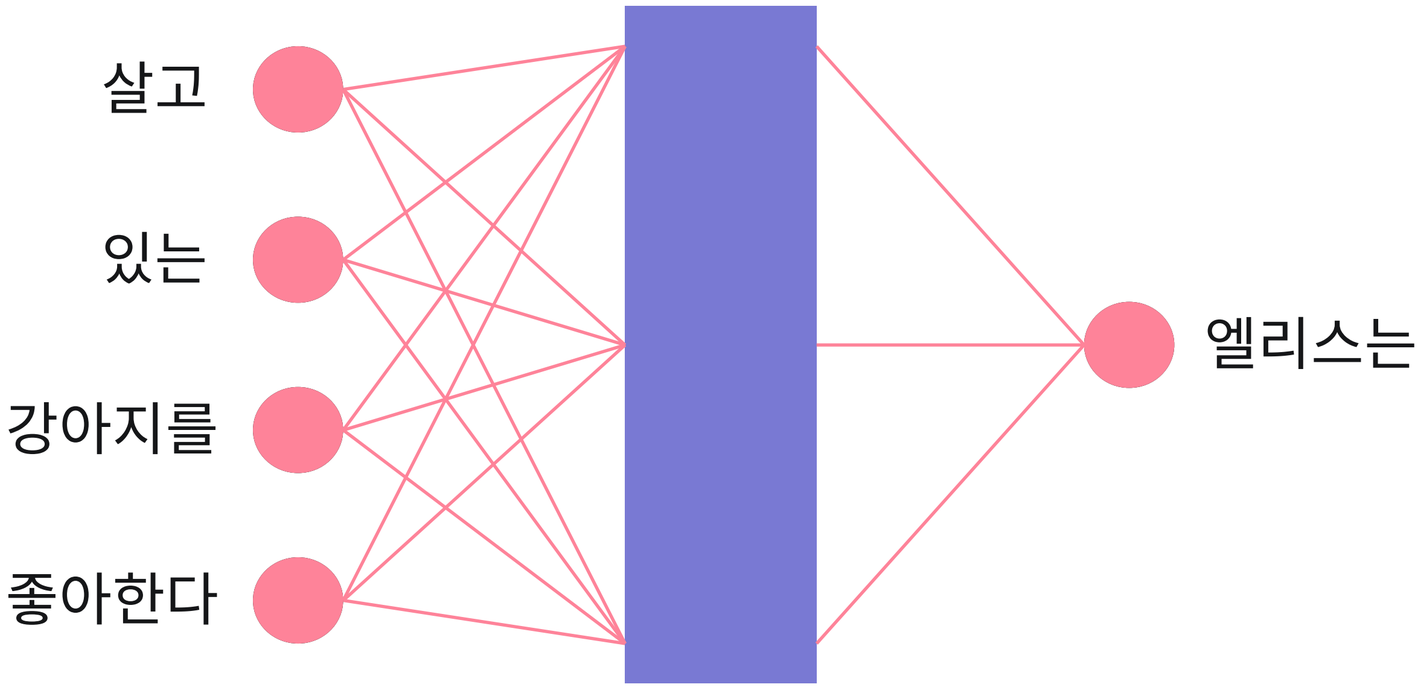

주어진 문맥에서 발생하는 단어를 예측하는 문제로 통해 단어 임베딩 벡터를 학습

word2vec

서울에 살고 있는 **엘리스는** 강아지를 좋아한다.

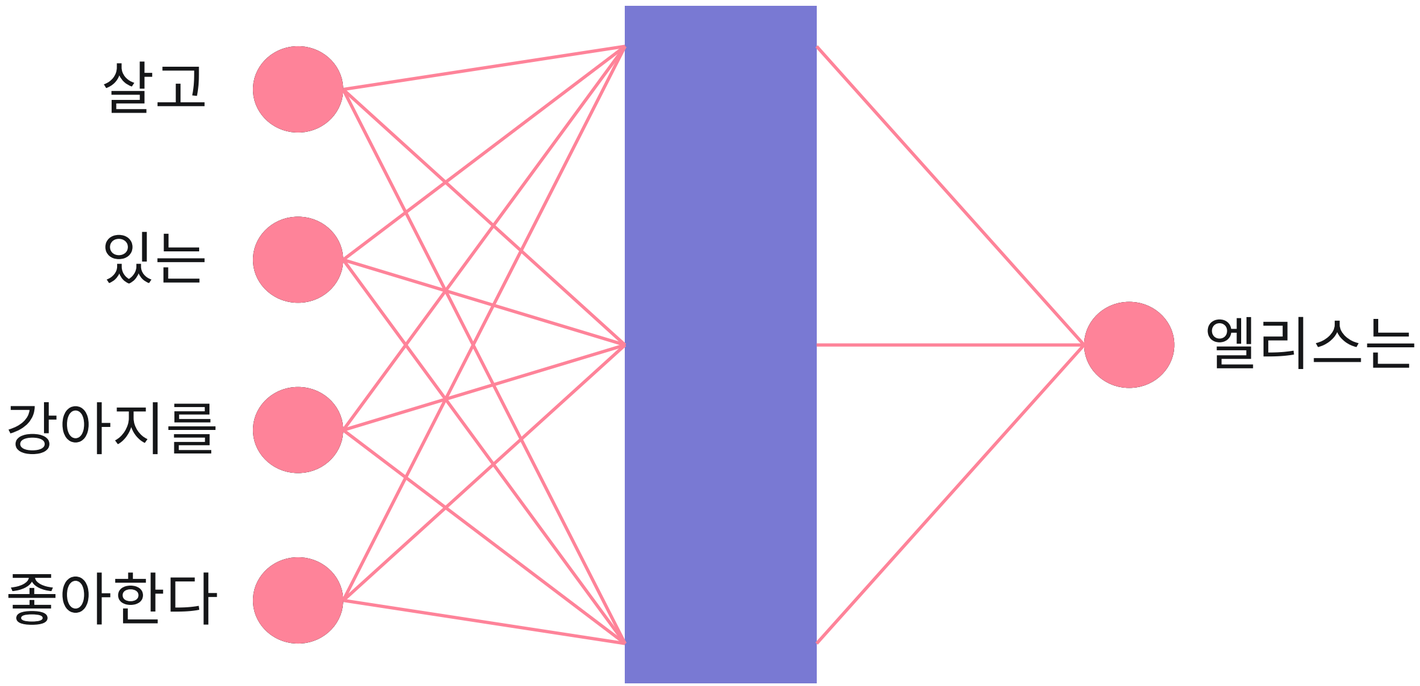

각 단어의 벡터는 해당 단어가 입력으로 주어졌을 때 계산되는 **은닉층의 값**을 사용

gensim

Example

```
from gensim.models import Word2Vec

doc = [["서울에", "살고", "있는", "엘리스는", "강아지를", "좋아한다"]]

w2v_model = Word2Vec(min_count=1, window=2, vector_size=300)

w2v_model.build_vocab(doc)

w2v_model.train(doc, total_examples=w2v_model.corpus_count, epochs=20)
```

gensim

Example

```
similar_word = w2v_model.wv.most_similar("엘리스는")
print(similar_word)
# [('있는', 0.05005083233118057), ('좋아한다', 0.03316839784383774),
   ('강아지를', 0.025744464248418808), ('서울에', 0.013042463921010494),
   ('살고', -0.034276079386472 7)]

score = w2v_model.wv.similarity("엘리스는", "좋아한다")
print(score)
# 0.03316839784383774
```

05

fastText

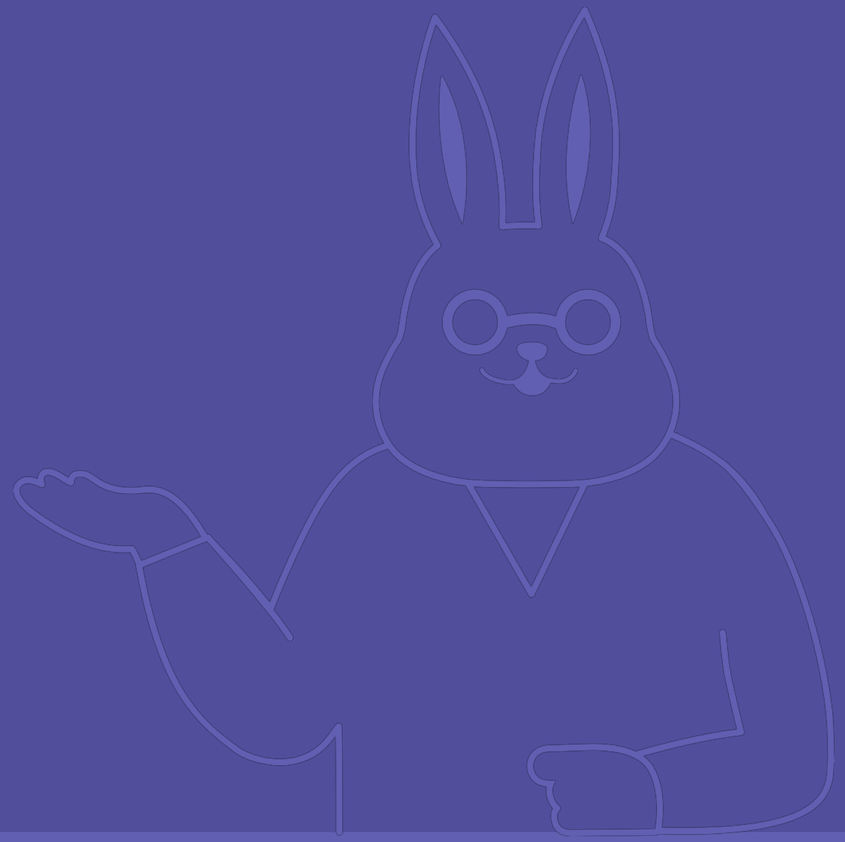

fastText

뉴욕에 살고 있는 찰리는 고양이를 좋아한다.

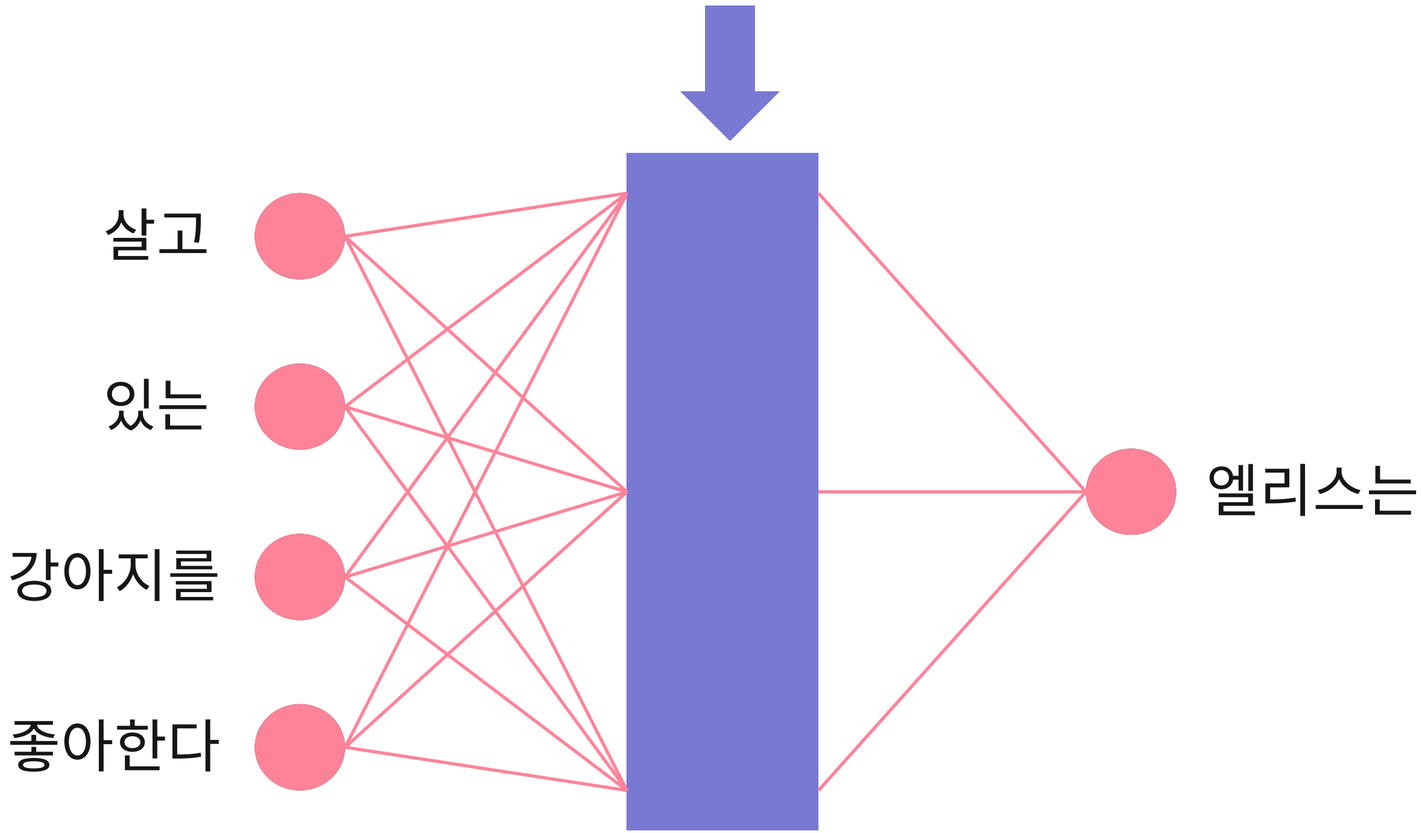

학습 데이터 내 **존재하지 않았던** 단어 벡터는 생성할 수 없음
(미등록 단어 문제, out-of-vocabulary)

fastText

서울에 살고 있는 **엘리스는** 강아지를 좋아한다.

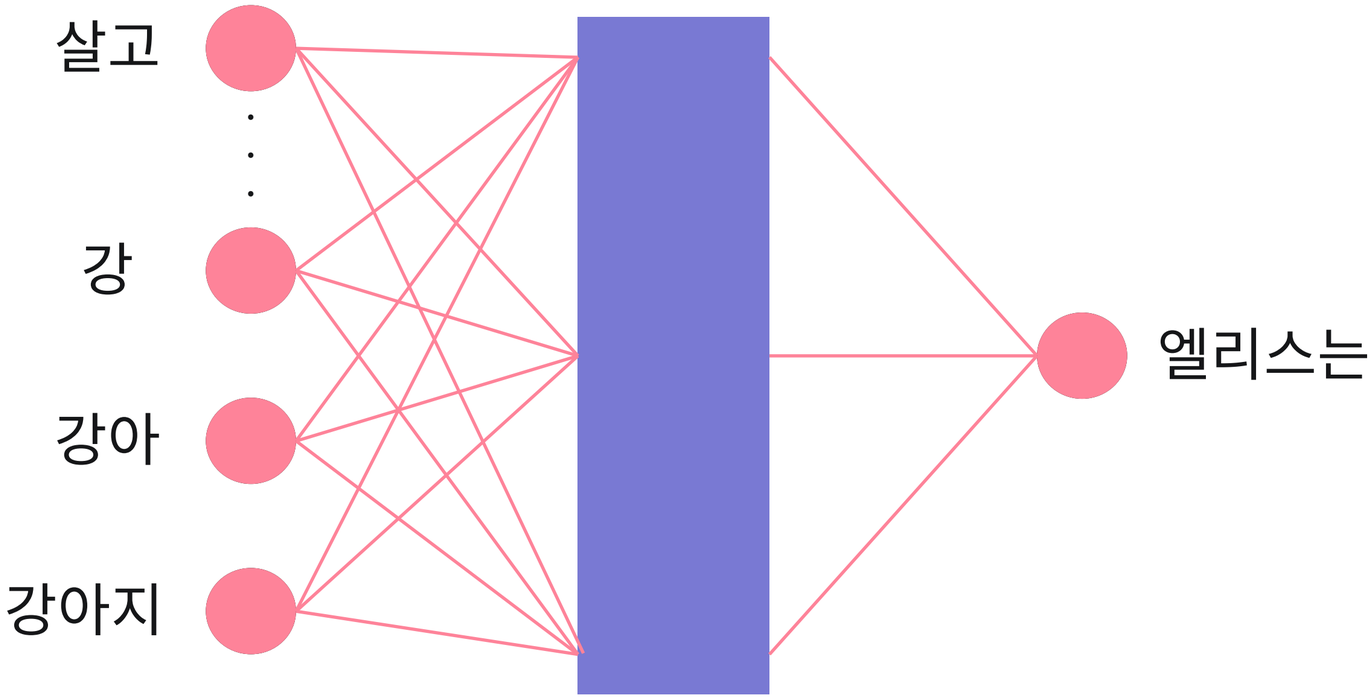

각 단어를 **문자 단위**로 나누어서 단어 임베딩 벡터를 학습

fastText

서울에 살**고** 있는 엘리스는 강아지를 **좋아한다**.

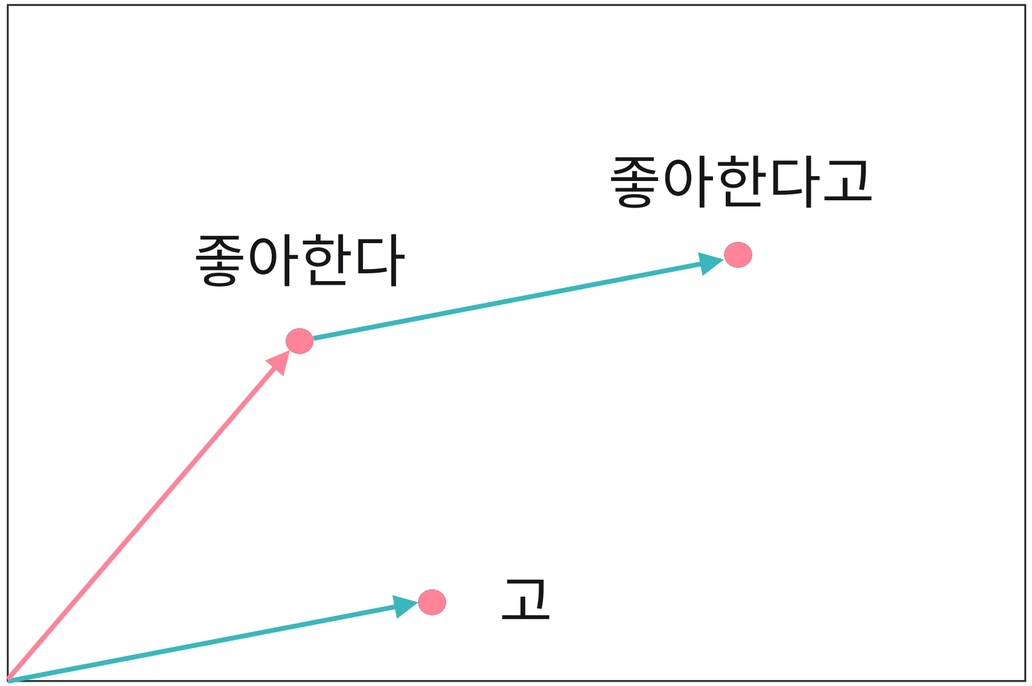

학습 데이터에 **존재하지 않았던** 단어의 임베딩 벡터 또한 생성 가능

gensim

Example

```
from gensim.models import FastText

doc = [["서울에", "살고", "있는", "엘리스는", "강아지를", "좋아한다"]]

ft_model = FastText(min_count=1, window=2, vector_size=300)

ft_model.build_vocab(doc)

ft_model.train(doc, total_examples=ft_model.corpus_count, epochs=20)
```

gensim

Example

```
similar_word = ft_model.wv.most_similar("엘리스는")
print(similar_word)
# [('좋아한다', 0.0311054792255163 2), ('살고', 0.01565768197178840 6),
  ('강아지를', -0.09297232329845428), ('서울에', -0.10255782306194305),
  ('있는', -0.10588616132736206)]

new_vector = ft_model.wv["좋아한다고”]
print(new_vector)
# array([-5.8544584e-04, -1.5485507e-03, -1.3994898e-03, -9.1309723e-04, ...
```